AV-HuBERT Baseline 实验报告

目录

- 摘要
- 一、任务与实验设计
- 二、实验配置
- 三、实验结果
- 四、结果分析
- 五、结论

摘要

本文根据 [[Initial Plan]]，围绕 **SSR-DFD 风格的 frozen AV-HuBERT linear probe baseline**，完成了两组 pilot 实验：
第一组是在 **AV-Deepfake1M (AV1M)** 上做 in-domain baseline；第二组是在 **MAVOS-DD English small** 上做 `open_set_model` 条件下的 unseen-generator pilot。当前结果表明，**冻结 AV-HuBERT + 单层线性头** 在 AV1M 上已经可以取得非常强的效果，`test_f1` 达到 **0.9895**；而在更难的 MAVOS-DD 英语开放集小样本上，最好验证表现达到 **val_f1=0.7785**，说明这一 baseline 仍然有效，但 open-set 条件明显更难。进一步比较 `10 / 50 / 100 epoch` 的结果可以看到，**增加训练轮数在 10 到 50 epoch 区间收益明显，但 50 到 100 epoch 已经进入边际收益递减区**，因此后续重点不应再只是继续增大 epoch，而应转向更完整的数据协议、阈值校准和更严格的泛化评估。

一、任务与实验设计

1. Baseline 思路

本文使用的检测框架与 [[Initial Plan]] 中的第一阶段设计一致，核心是验证：

- 预训练 `AV-HuBERT (audio-visual)` 表征是否已经足够强
- 在 backbone 全冻结时，仅训练轻量分类头，是否仍能在 deepfake detection 上取得有效结果

整体结构保持为：

模块	当前实现
Backbone	预训练 `AV-HuBERT (audio-visual)`
参数策略	冻结 backbone，仅训练线性分类头
分类头	`Linear(1024, 1)`
聚合	`log-sum-exp pooling`
输入	`mouth ROI video + cached audio features`
损失	`BCEWithLogitsLoss`

2. 当前实际使用的数据切片

当前并未直接覆盖 [[Initial Plan]] 中提到的全部数据集，而是先完成两个 pilot：

数据集	当前使用的数据切片	作用
AV1M	`AV-Deepfake1M/val` 中的 `real.mp4` 与 `fake_video_fake_audio.mp4`	建立 in-domain 强 baseline
MAVOS-DD	`English small`，其中 `train` 按 `1/5` 抽样，`val` 全量，`test` 为 `open_set_model=true` 的 `1/5` 抽样	观察 unseen-generator 条件下的初步泛化能力

当前 MAVOS-DD 英语小样本的有效样本规模为：

Split	原始 split 数量	预处理后可用样本数
Train	1277	1237
Val	1079	1036
Test	1590	1477

> 这里的 MAVOS-DD 实验是 **English-only + open_set_model pilot**，不是完整的 MAVOS-DD 全量 benchmark。

二、实验配置

三个数据集实验共享的核心训练参数如下：

参数	数值
`max_frames`	`300`
`image_crop_size`	`88`
`learning_rate`	`1e-3`
`weight_decay`	`1e-4`
`grad_clip_norm`	`5.0`
`amp`	`false`
训练方式	8 卡 DDP

本次实际对比的 run 配置如下：

实验	输出目录	Epoch	Batch Size	Devices
AV1M baseline	20260411-040113	10	4	8 GPUs
MAVOS Run A	20260412-051856	10	8	8 GPUs
MAVOS Run B	20260412-052419	50	4	8 GPUs
MAVOS Run C	20260412-054048	100	4	8 GPUs

三、实验结果

1. AV1M baseline 结果

来源：

- summary.json

指标	数值
best_epoch	10
best_val_f1	0.9871
test_accuracy	0.9892
test_precision	0.9966
test_recall	0.9825
test_f1	0.9895
test_loss	0.0395

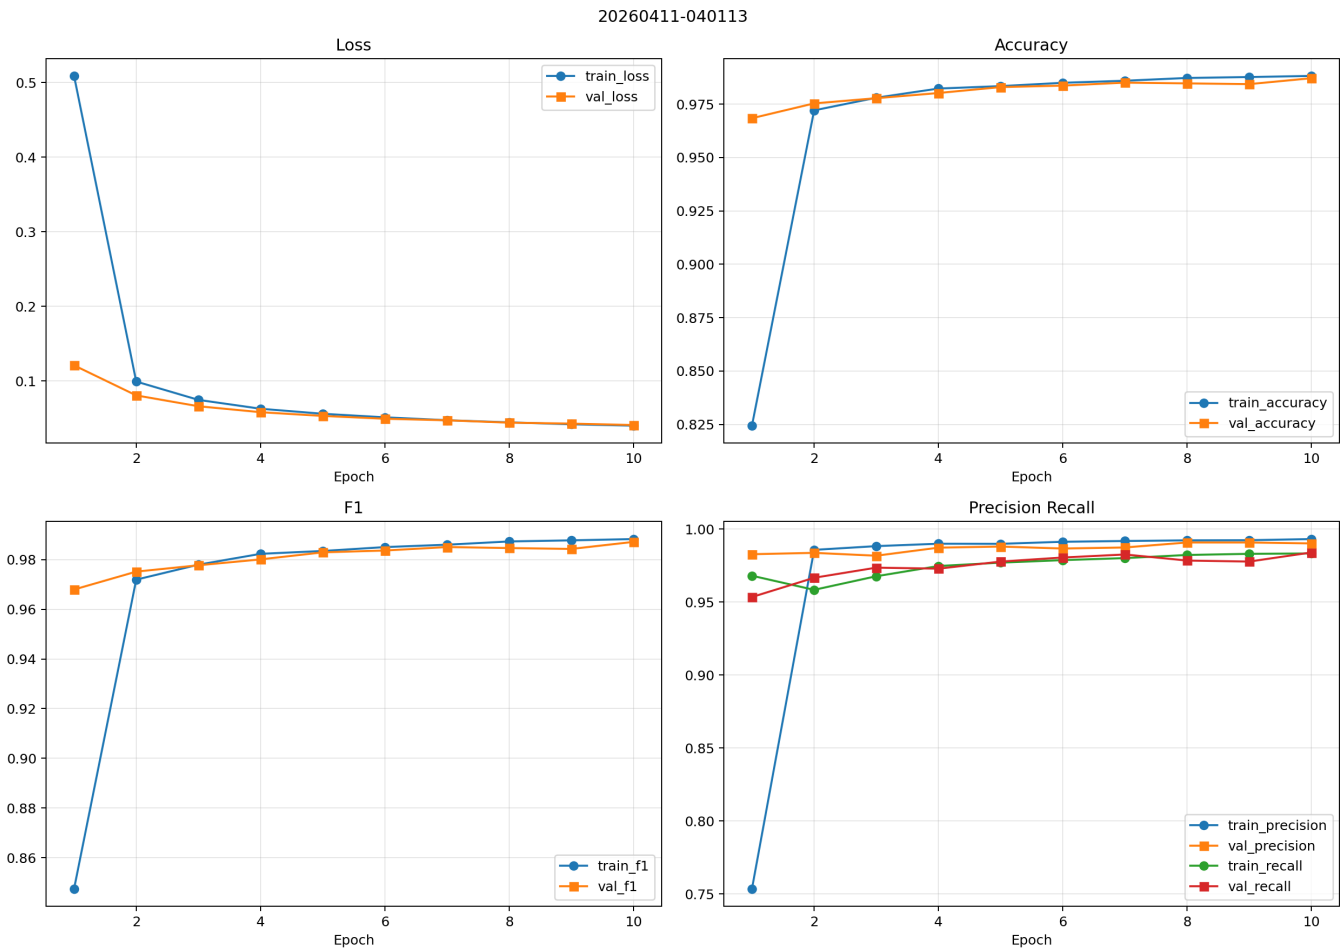

图 1：AV1M in-domain baseline 训练曲线，配置为 `epochs=10`、`batch_size=4`、`8 GPUs`。该图对应 20260411-040113，可见在当前 AV1M 切片上模型很快收敛，`10 epoch` 已足够达到稳定高性能。

2. MAVOS-DD English small 结果对比

来源：

- 20260412-051856/summary.json
- 20260412-052419/summary.json
- 20260412-054048/summary.json

Run	Epoch	Batch	Best Epoch	Best Val F1	Test Acc	Test Precision	Test Recall	Test F1	Test Loss
20260412-051856	10	8	10	0.7072	0.6405	0.6568	0.9529	0.7776	0.8898
20260412-052419	50	4	48	0.7579	0.6655	0.7503	0.7387	0.7445	0.6484
20260412-054048	100	4	99	0.7785	0.6689	0.7780	0.6967	0.7351	0.6812

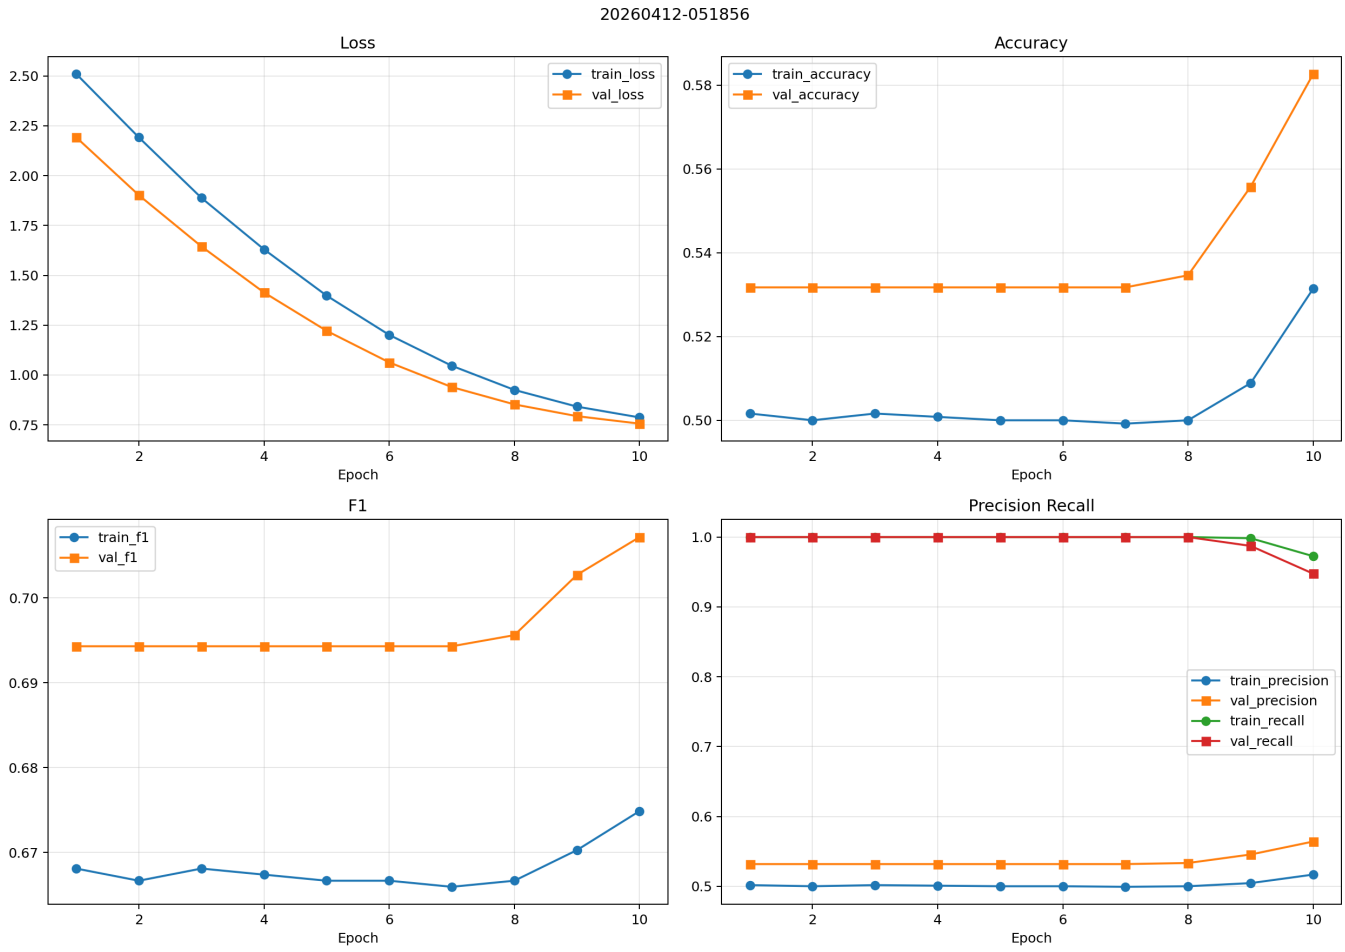

图 2：MAVOS-DD English small，Run A 的训练曲线，配置为 `epochs=10`、`batch_size=8`、`8 GPUs`。该图对应 20260412-051856，主要用于观察短训练轮数下的快速 baseline 表现。

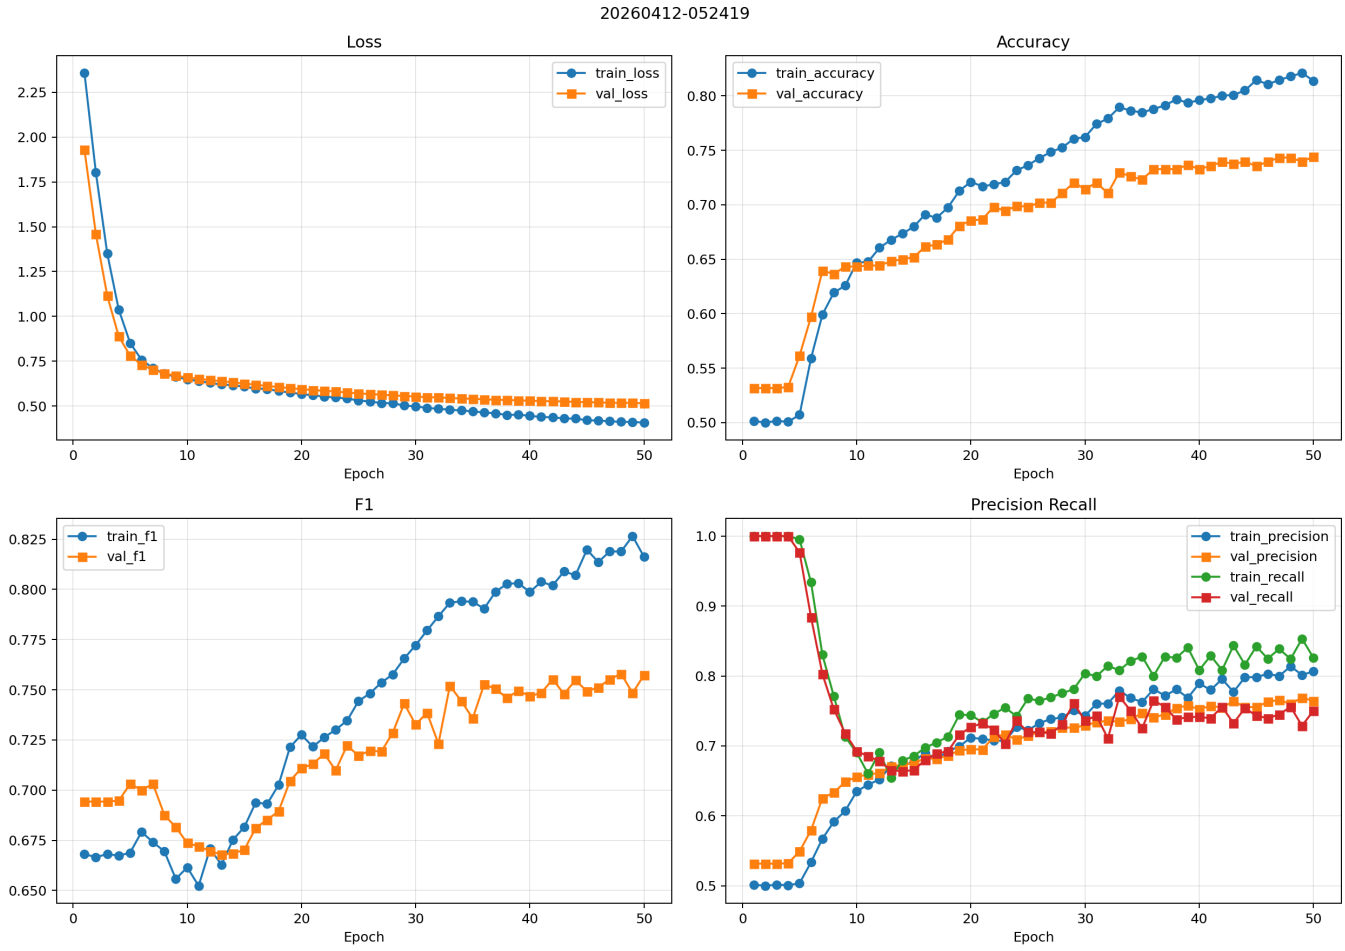

图 3：MAVOS-DD English small，Run B 的训练曲线，配置为 `epochs=50`、`batch_size=4`、`8 GPUs`。该图对应 20260412-052419，可以看到相比 10 epoch，验证集指标有明显提升。

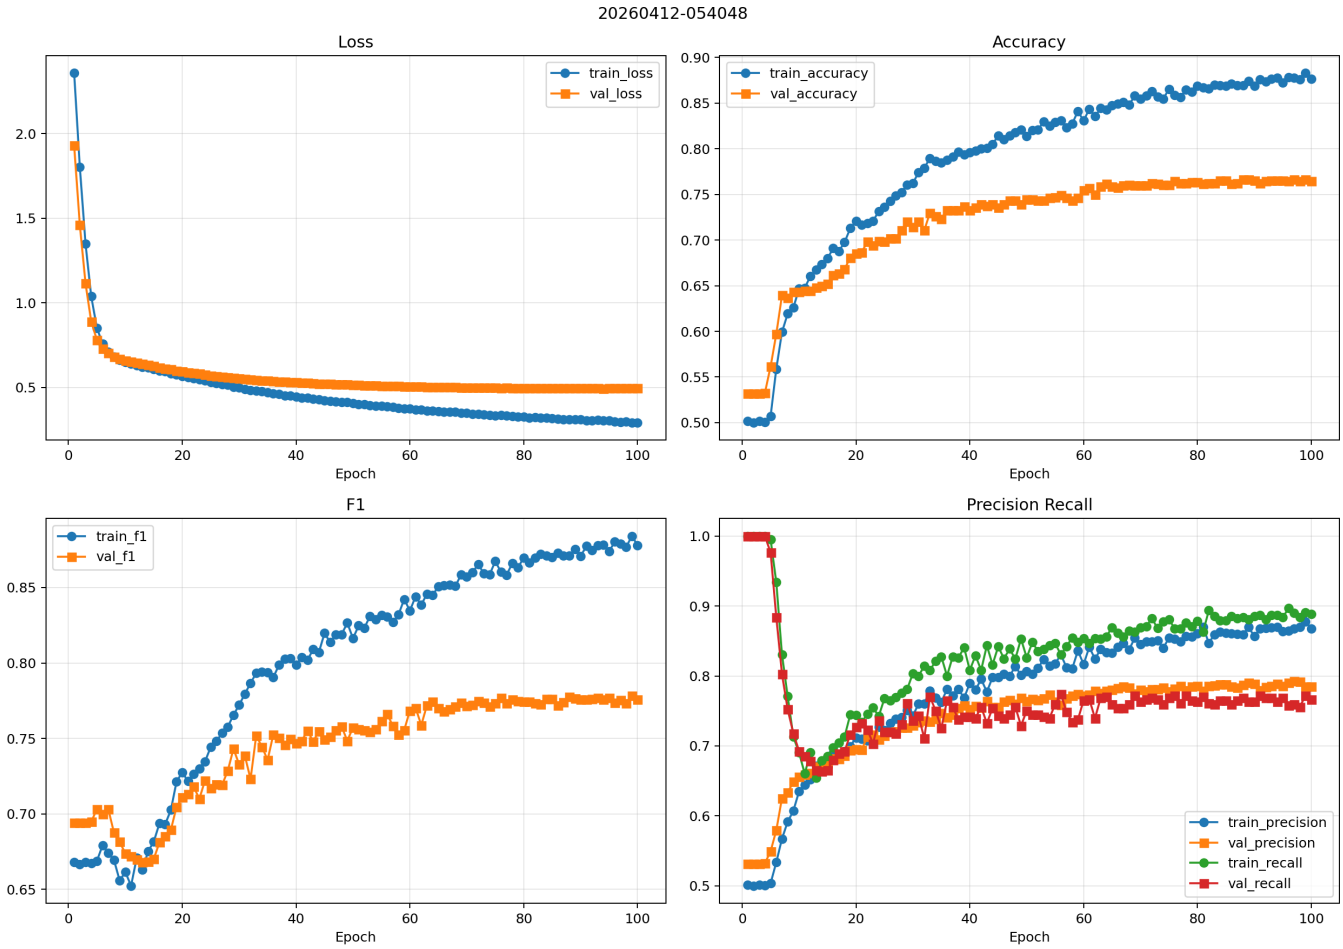

图 4：MAVOS-DD English small，Run C 的训练曲线，配置为 `epochs=100`、`batch_size=4`、`8 GPUs`。该图对应 20260412-054048，显示模型在更长训练下继续收敛，但后期收益已明显趋缓。

四、结果分析

1. Frozen AV-HuBERT baseline 是否成立

结论是 **成立**。

证据很直接：

- 在 AV1M in-domain pilot 上，`test_f1 = 0.9895`
- 在 MAVOS-DD English small open-set pilot 上，最好验证表现达到 `0.7785`

这说明冻结的自监督 `AV-HuBERT` 表征本身已经携带了足够强的判别信息，单层线性头就可以构成一个有解释力的 baseline。

2. Open-set model 是否明显更难

结论是 **明显更难**。

从结果对比可以看到：

- AV1M pilot：`test_f1 = 0.9895`
- MAVOS-DD English small：最好 `test_f1` 约在 `0.735 ~ 0.745`

这说明当分布从“较接近同分布的 AV1M pilot”迁移到“英语 unseen-generator pilot”后，性能出现了显著下降。这个现象和 [[Initial Plan]] 中“第二阶段更强调泛化压力”的判断一致。

3. Epoch 增大是否还值得继续

结论是 **10 到 50 epoch 很值得，50 到 100 epoch 收益已经明显变小**。

具体表现：

- `10 -> 50 epoch`
  - `best_val_f1: 0.7072 -> 0.7579`
  - 收益明显
- `50 -> 100 epoch`
  - `best_val_f1: 0.7579 -> 0.7785`
  - 有收益，但已经接近平台区

同时，`100 epoch` 虽然取得了最高的 `best_val_f1`，但 test `F1` 没有继续提升，反而表现出更保守的预测风格：

- `precision` 上升
- `recall` 下降

因此当前更合理的判断是：

- 单纯继续无上限增大 epoch 的价值已经不大
- 后续更值得尝试的是：
  - 阈值校准
  - 更完整的 MAVOS-DD 测试协议
  - 更大范围的数据切片

五、结论

结合 [[Initial Plan]]，当前实验可以给出一个阶段性结论：

1. **已验证**：
   frozen `AV-HuBERT + linear probe` 是一个成立且足够强的 baseline。

2. **已验证**：
   同一套框架可以从 AV1M 平滑迁移到 MAVOS-DD English small，并在 unseen-generator 条件下保持可用表现。

3. **已验证**：
   open-set / unseen model 条件明显比 AV1M 当前 in-domain pilot 更难。

4. **部分验证**：
   增大训练轮数确实有帮助，但收益主要集中在 `10 -> 50 epoch`，到 `100 epoch` 已经进入边际收益递减区。

5. **尚未完成**：
   当前还没有完成：

   - FAVC / AV1M 的严格 cross-dataset 对齐

    - MAVOS-DD 全量 out-of-model benchmark
    - MVAD 扩展实验

因此，当前最准确的总结是：

> **我们已经完成了一个可信的 AV-HuBERT baseline pilot：它在 AV1M 上非常强，在 MAVOS-DD English small 的 open-set model 条件下也具备可用的泛化能力；但开放集场景显著更难，后续工作的重点不应只是继续增加 epoch，而应转向更完整的评估协议和更复杂分布上的验证。**